

中文普通话语音数据库

[AISHELL-ASR009-OS1]

训练及测试数据集

1 产品概述.....	2
2 录音语料.....	2
2.1 语料池的制作.....	2
2.1.1 语料池内容	2
2.1.2 语料池处理	3
2.2 录音文本的结构设计.....	3
3 发音人信息.....	3
3.1 基本信息记录.....	3
3.2 发音人结构特征.....	4
3.2.1 性别比例	4
3.2.2 年龄比例	4
3.2.3 方言区域比例	4
4 数据录制环境.....	5
4.1 录制环境.....	5
4.2 录制设备.....	5
4.3 录制方法.....	5
5 语音数据转写.....	6
6 数据文件目录.....	6
6.1 目录结构.....	6
6.2 命名规则.....	7
6.2.1 目录命名规则.....	7
6.2.2 文件命名规则.....	7
7 AISHELL-ASR0009-OS1 数据集分配.....	7

1 产品概述

此中文普通话语音数据库[AISHELL-ASR0009]录音文本涉及智能家居、无人驾驶、工业生产等 11 个领域。来自中国不同口音区域发音人参与录制。录制过程在安静室内环境中，同时使用 3 种不同设备：高保真麦克风（44.1kHz，16bit）；Android 系统手机（16kHz，16bit）；iOS 系统手机（16kHz，16bit）。

此数据库经过专业语音校对人员转写标注，并通过严格质量检验，文本正确率在 95%以上。开源数据[AISHELL-ASR0009-OS1] 共 178 小时，抽取 400 名男女平衡高保真麦克风数据，数据格式降采样为 16kHz。数据分为训练集、开发集、测试集。

此数据库仅支持学术研究，未经允许禁止商用。

2 录音语料

2.1 语料池的制作

2.1.1 语料池内容

考虑到语音识别在智能家居、无人驾驶、工业生产等领域的应用，语料在 11 个领域中选定，[AISHELL-ASR0009-OS1]抽取 6-10 的 5 类内容。（图表 2-1）

序号	领域
1	家居家电名称和控制命令
2	POI（地理信息）
3	音乐类（语控）
4	数字类（语控）
5	电视、电影名称
6	财经
7	科技
8	体育
9	娱乐
10	时事新闻

图表 2-1 语料池内容

2.1.2 语料池处理

- 脱敏处理。删除政治敏感、个人隐私、色情暴力等内容。
- 删除 <, >, [,], ~, /, \, = 等符号。
- 删除含有中文和英文以外语言的内容。
- 删除单句含有 25 字以上的内容。
- 统一格式。

2.2 录音文本的结构设计

考虑到语音覆盖及音素平衡，此数据库录音文本采用每份 500 句的分配方式设计，从语料池中抽取，结构如下。[AISHELL-ASR0009-OS1]抽取 6-10 的 5 类内容。（图表 2-2）

序号	领域	每份分配量/句
1	家居家电和控制名称	5
2	POI (地理信息)	30
3	音乐类 (语控)	46
4	数字类 (语控)	29
5	电视、电影名称	10
6	财经	132
7	科技	85
8	体育	66
9	娱乐	27
10	时事新闻	66
11	英文拼读	4
合计	11 项	500 句

图表 2-2

3 发音人信息

3.1 基本信息记录

发音人信息记录内容包括任务编号、性别、口音区域、年龄区间、籍贯。（图表 3-1）

任务编号	性别	口音区域	年龄区间	籍贯
------	----	------	------	----

0001	男	北方	A	河北
------	---	----	---	----

图表 3-1

任务编号：每个发言人领取 1 个任务编号，每个任务编号对应 1 份录音文本。每个发言人只能参加一次录制。

口音区域：按照发言人原生语言所属区域，分为北方、南方、粤贵闽、其他。

年龄区间：A(16-25 岁)、B(26-40 岁)、C(41 岁以上)。

籍贯：记录发言人身份证所示籍贯信息。

3.2 发音人结构特征

3.2.1 性别比例

数据库总人数为 400 人，男 186 人，女 214 人。（图表 3-2-1）

性别	男性	女性	合计
比例	47%	53%	100%

图表 3-2-1

3.2.2 年龄比例

A(16-25 岁)316 人；B(26-40 岁)71 人；C(41 岁以上)13 人。（图表 3-2-2）

	年龄段	人数	比例	男性	女性
A	16-25 岁	316	79%	140	176
B	26-40 岁	71	18%	36	35
C	> 41 岁	13	3%	10	3
合计		400	100%	186	214

图表 3-2-2

3.2.3 方言区域比例

北方 333 人；南方 38 人；粤贵闽 18 人；其他 11 人。（图表 3-2-3）

区域	人数	比例
北方	333	83%

南方	38	10%
粤贵闽	18	4%
其他	11	3%
合计	400	100%

图表 3-2-3

4 数据录制环境

4.1 录制环境

安静室内，不包括明显的其他人说话声音及其他噪音，无回音。发言人按照正常语速，朗读录音文本。

4.2 录制设备

录制设备包括高保真麦克风和录音机、iOS 系统手机、Android 系统手机。

4.3 录制方法

发音人距离高保真麦克风 20 厘米，以讲话正常音量，正常语速，朗读录音文本。Android 系统手机与 iOS 系统手机分别与麦克风间隔 20 厘米布置。（图表 4-3）



图表 4-3

5 语音数据转写

数据转写人员根据所听到的音频写出内容，力求使文本内容与音频发音内容保持一致。一般准则如下：

- 1) 转写的内容必须和听到的语音完全一致，不能多字、少字、错字。
- 2) 数字要转写为汉字形式，如“一二三”，而不是“123”。注意区分“一”和“幺”，“二”和“两”。
- 3) 音频中有英文发音的应写成相应的汉字或英文。具体分为以下几种情况：
 - 网址中包含的所有的字母或单词，均为大写。例如：发音内容为“www.abc.com”，应转写为“三 W 点 A B C 点 com”
 - 发音中包含的英文单词，转写时全部为小写。
 - 发音中包含的英文字母，转写时全部为大写。
 - 对于一些大写专有名词，或者一些英文缩写全部大写加空格，例如：CEO、CCTV 等。
- 4) 标注内容的完整性要与实际发音一致，不得删减。

6 数据文件目录

6.1 目录结构

数据目录树	
数据目录结构	
中文普通话语音数据_产品说明.docx	(数据库简介)
└─DOC	(文本说明文件)
└─all_wav_list.txt	(音频列表)
└─content.txt	(转写内容列表)
└─readme.txt	(目录说明文件)
└─spkrinfo.xlsx	(录音人信息)
└─SPEECHDATA	(数据文件夹)
└─C0001	(录音人文件夹)
BAC0009C0001W0001.wav	(音频文件)
BAC0009C0001W0001.txt	(语音内容文本)

6.2 命名规则

6.2.1 目录命名规则（图表 6-2-1）

/<CORPUS>/<USAGE>/<FILE_ID>/<SPEECH_ID>

e. g. 中文普通话数据库/SPEECHDATA/C0001/BAC0009C0001W0001.wav

目录	内容	备注
CORPUS	中文普通话语音数据	数据库名称
USAGE	SPEECHDATA	文件夹名称
FILE_ID	C0001	录音人文件夹名称
SENTENCE_ID	BAC0009C0001W0001.txt	TXT 文件
SPEECH_ID	BAC0009C0001W0001.wav	WAV 文件

图表 6-2-1

6.2.2 文件命名规则（图表 6-2-2）

<CORPUS_ID><SPEAKER_IC><WAV_NUM>

e. g. BAC0009C0001W0001.wav

文件	内容	备注
CORPUS_ID	BAC009	数据库名称
SPEAKER_NUM	C0001	录音人 ID
WAV_NUM	W0001	WAV 编号

图表 6-2-2

7 AISHELL-ASR0009-OS1 数据集分配

数据集分配如下：

数据集	小时	女	男	总人数
训练集	150	161	179	340
开发集	18	12	28	40
测试集	10	13	7	20